PROJETO DE ANÁLISE DE DADOS

1. Equipe

Robério Batista de Azevêdo Júnior • Daniel Goes

2. Problema a ser investigado

O projeto pretende investigar como características pessoais, principalmente o tabagismo, a idade e o índice de massa corporal (IMC), estão associadas aos custos médicos registrados em um conjunto de dados de beneficiários de seguros de saúde dos Estados Unidos.

A análise buscará identificar diferenças entre os custos de fumantes e não fumantes, além de observar variações relacionadas à idade e ao IMC.

3. Conjunto de dados

Base selecionada: Medical Cost Personal Datasets (insurance.csv), disponível no Kaggle. O conjunto contém 1.338 registros e 7 colunas. Cada linha representa um beneficiário.

Coluna	Descrição
age	Idade da pessoa (anos)
sex	Sexo (female/male)
bmi	Índice de Massa Corporal (IMC)
children	Número de dependentes
smoker	Condição de tabagismo (yes/no)
region	Região dos Estados Unidos
charges	Custos médicos individuais cobrados (US$)

Fonte original: https://www.kaggle.com/datasets/mirichoi0218/insurance

4. Análise exploratória dos dados (EDA)

A exploração inicial contempla estrutura do DataFrame, identificação de valores ausentes e duplicados, estatísticas descritivas e distribuição de categorias. As operações podem ser reproduzidas com as funções Pandas abaixo.

Verificação	Resultado
Dimensões (shape)	1.338 linhas × 7 colunas
Tipos dos dados (dtypes)	2 inteiros, 2 decimais e 3 textos
Valores ausentes (isna().sum())	0 em todas as colunas
Registros duplicados (duplicated().sum())	1
Idade (describe())	18 a 64 anos; média de 39,21 anos
IMC (describe())	15,96 a 53,13; média de 30,66
Custos (describe())	Média: US$ 13.270,42; mediana: US$ 9.382,03
Custos mínimo e máximo	US$ 1.121,87 e US$ 63.770,43
Tabagismo (value_counts())	274 fumantes; 1.064 não fumantes

5. Exemplos de comandos em Pandas

```
import pandas as pd
df = pd.read_csv("insurance.csv")
print(df.shape)                      # (1338, 7)
print(df.dtypes)                    # tipos das colunas
print(df.isna().sum())              # valores ausentes
print(df.duplicated().sum())        # registros duplicados
print(df[["age", "bmi", "charges"]].describe().round(2))
print(df["smoker"].value_counts())
print(df.groupby("smoker")["charges"].mean().round(2))
```

Comparação inicial: a média dos custos registrados é de US$ 32.050,23 entre fumantes e US$ 8.434,27 entre não fumantes. Trata-se de uma associação observada nos dados, sem demonstrar causalidade.

6. Observação sobre a interpretação

A coluna charges corresponde a custos médicos individuais cobrados, não à mensalidade do plano. A documentação da base não confirma se o período de referência é mensal ou anual; por isso, essa periodicidade não será presumida na análise.