TÉCNICAS DE ANÁLISE DE DADOS

Atividade 2 – Pré-processamento de Dados

Alunos: Robério Júnior e Daniel Goes

Conjunto de dados: Medical Cost Personal Datasets

1. Procedimentos e justificativas

Verificação inicial: foram conferidas as dimensões do arquivo, os tipos de dados, os valores ausentes, os registros duplicados e a distribuição da variável smoker. Essa etapa ajuda a identificar problemas de qualidade e entender as características do conjunto.

Tratamento de duplicatas: a análise encontrou 1 registro repetido. Por isso, foi utilizado drop_duplicates(), reduzindo o conjunto de 1.338 para 1.337 linhas. Não foi necessário preencher valores ausentes, pois nenhuma coluna apresentou valores faltantes.

Separação das variáveis: age, bmi e children foram consideradas numéricas. sex, smoker e region foram tratadas como categóricas. A variável charges foi separada como alvo, pois representa o custo médico individual registrado no conjunto de dados.

Divisão treino/teste: os dados foram separados em 80% para treino e 20% para teste. O parâmetro random_state=42 permite reproduzir a divisão. A estratificação por smoker ajuda a manter proporções semelhantes de fumantes e não fumantes nos dois grupos.

Padronização e codificação: StandardScaler foi aplicado às variáveis numéricas, colocando-as em escalas comparáveis. OneHotEncoder converteu as categorias em colunas numéricas, necessárias para muitos algoritmos. O parâmetro handle_unknown='ignore' evita erro caso apareça uma categoria não observada no treino.

2. Resultados obtidos

Verificação	Resultado
Dimensões iniciais	1.338 linhas × 7 colunas
Valores ausentes	Nenhum
Registros duplicados identificados	1
Dimensões após remoção de duplicata	1.337 linhas × 7 colunas
Conjunto de treino	1.069 registros; 11 variáveis preparadas
Conjunto de teste	268 registros; 11 variáveis preparadas
Variável-alvo	charges, mantida em dólares

A variável charges apresentou média de US$ 13.270,42 e mediana de US$ 9.382,03 na análise inicial. Também foi observada diferença na média dos custos entre fumantes (US$ 32.050,23) e não fumantes (US$ 8.434,27). Esses valores são descritivos e, por si só, não demonstram causalidade.

3. Código utilizado

O código abaixo reproduz os procedimentos executados. O arquivo insurance.csv deve estar na mesma pasta do script. Ao executar o programa, será criado o arquivo insurance_limpo.csv.

```
import pandas as pd
from sklearn.compose import ColumnTransformer
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder, StandardScaler

# 1. Leitura e verificacao inicial dos dados
df = pd.read_csv("insurance.csv")

print("Dimensoes originais:", df.shape) print("Tipos de
dados:\n", df.dtypes)
print("Valores ausentes por coluna:\n", df.isna().sum())
print("Registros repetidos:", df.duplicated().sum())
print("Distribuicao do tabagismo:\n",
df["smoker"].value_counts()) print("Resumo dos custos:\n",
df["charges"].describe())

# 2. Remoção de registros duplicados
df = df.drop_duplicates().copy()
df.to_csv("insurance_limpo.csv", index=False) print("Dimensoes
após a limpeza:", df.shape)

# 3. Separação das variáveis de entrada e da variável-alvo
variaveis_numericas = ["age", "bmi", "children"]
variaveis_categoricas = ["sex", "smoker", "region"]

X = df[variaveis_numericas + variaveis_categoricas] y =
df["charges"]

# 4. Divisao em treino e teste
X_treino, X_teste, y_treino, y_teste = train_test_split(
  X, y, test_size=0.20, random_state=42, stratify=X["smoker"]
)

# 5. Preparação das variáveis numéricas e categóricas
preprocessador = ColumnTransformer(
  transformers=[
    ("numericas", StandardScaler(), variaveis_numericas),
    ("categoricas", OneHotEncoder(handle_unknown="ignore"),
     variaveis_categoricas),
  ]
)

# Ajusta o preprocessador no treino e aplica ao teste
X_treino_preparado = preprocessador.fit_transform(X_treino)
X_teste_preparado = preprocessador.transform(X_teste)
```

```
# 6. Conferência dos resultados
print("Treino - dados preparados:", X_treino_preparado.shape)
print("Teste - dados preparados:", X_teste_preparado.shape)
print("Colunas preparadas:\n",
preprocessador.get_feature_names_out()) print("Alvo mantido em
dolares; treino:", y_treino.shape)
print("Alvo mantido em dólares; teste:", y_teste.shape)
```

4. Considerações finais

O pré-processamento foi executado sem erros. O arquivo insurance_limpo.csv foi criado com os registros duplicados removidos. Os dados de entrada foram separados em treino e teste e as variáveis foram transformadas conforme seus tipos.