INSTITUTO FEDERAL DO RIO GRANDE DO NORTE – IFRN
Campus Currais Novos

TÉCNICAS DE ANÁLISE DE DADOS

Atividade 3 – Agrupamento (clusterização) dos dados

Professor: Marcílio Meira
Alunos: Robério Batista de Azevêdo Júnior e Daniel Goes

Conjunto de dados: Medical Cost Personal Datasets (insurance.csv)

Currais Novos – RN

1. Objetivo

Esta atividade aplica dois algoritmos de agrupamento não supervisionado, K-Means e Agrupamento Hierárquico Aglomerativo, ao conjunto de dados de custos médicos (insurance.csv). O objetivo é identificar grupos nos atributos de entrada e comparar os clusters com três faixas de custo, chamadas Baixo, Médio e Alto.

Esclarecimento: a coluna charges contém valores contínuos. As três faixas não são rótulos originalmente existentes no arquivo; foram criadas por discretização em quantis para possibilitar essa comparação.

2. Metodologia de Agrupamento

Foram utilizados os dados de treinamento preparados na Atividade 2 – Pré-processamento de Dados, com 1.069 registros e 11 atributos transformados. O código completo de carregamento, limpeza, codificação e padronização foi entregue na atividade anterior e é reutilizado por esta etapa, sem necessidade de repeti-lo neste documento.

A variável-alvo charges foi mantida fora dos atributos usados para formar os clusters. Somente seus valores no conjunto de treinamento foram convertidos em três faixas usando pd.qcut(), para avaliação posterior dos grupos.

A escolha de K = 3 permite comparar os clusters produzidos pelos dois algoritmos com as três faixas de custo criadas. Não se afirma que três seja o número ótimo de grupos.

K-Means: particionamento em três grupos com base em centróides (`n_clusters=3`, `random_state=42` e `n_init=10`).
Aglomerativo: agrupamento hierárquico em três grupos pelo método de Ward, com distância euclidiana.

3. Resultados Obtidos

Foram consideradas duas métricas externas, ARI (Adjusted Rand Index) e NMI (Normalized Mutual Information), que comparam as atribuições de clusters às faixas de custo, além da métrica interna Silhouette, que avalia a separação dos grupos.

Métrica de avaliação	K-Means	Hierárquico
ARI (Adjusted Rand Index)	0,204379	0,136107
NMI (Normalized Mutual Information)	0,213334	0,133954
Coeficiente de Silhueta	0,185624	0,129670

4. Matrizes de Contingência (Distribuição dos Grupos)

Distribuição dos clusters K-Means por faixa de custo

Faixa de charges	Cluster 0	Cluster 1	Cluster 2
Baixo	79	261	17
Médio	134	11	211
Alto	111	110	135

Distribuição dos clusters hierárquicos por faixa de custo

Faixa de charges	Cluster 0	Cluster 1	Cluster 2
Baixo	66	60	231
Médio	200	134	22
Alto	94	114	148

Nas tabelas, os identificadores 0, 1 e 2 são rótulos arbitrários dos clusters e não correspondem automaticamente a Baixo, Médio e Alto.

5. Considerações Finais

Na execução verificada, o K-Means obteve valores superiores nas três métricas, indicando maior concordância com as faixas de custo e melhor separação interna em comparação com o método hierárquico nesta execução.

Entretanto, os valores de ARI, NMI e Silhouette são relativamente baixos. Portanto, a concordância dos clusters com as três faixas e a separação entre os grupos são limitadas. Esses números, isoladamente, não demonstram que os dados sejam não lineares nem comprovam que o tabagismo seja a causa das diferenças de custos.

6. Código-fonte utilizado

O código desta atividade está a seguir, conforme a versão executada no repositório. Ele importa a função `preparar_dados()` de `codigo/atividade_02_preprocessamento.py`, entregue na Atividade 2, e utiliza `dados/insurance.csv`. Assim, o pré-processamento permanece documentado na entrega anterior, sem duplicação de código.

Os resultados e as matrizes de contingência são exibidos no terminal e exportados em arquivos CSV na pasta resultados/ para facilitar a conferência.

```
"""IFRN - Atividade 3: Agrupamento do Medical Cost Personal Datasets.
Dupla: Robério Batista de Azevêdo Júnior e Daniel Goes.
O código de pré-processamento consta da entrega da Atividade 2.
"""

from pathlib import Path
import pandas as pd
from sklearn.cluster import KMeans, AgglomerativeClustering
from sklearn.metrics import (
    adjusted_rand_score, normalized_mutual_info_score, silhouette_score,
)
from atividade_02_preprocessamento import preparar_dados

RAIZ = Path(__file__).resolve().parents[1]
RESULTADOS = RAIZ / "resultados"


def main():
    # 1. Reutilizar o pré-processamento implementado na Atividade 2.
    X_treino_preparado, _, y_treino, _ = preparar_dados()

    # 2. Discretizar charges em faixas de custo SOMENTE para avaliação.
    # As classes Baixo, Médio e Alto não existem originalmente no CSV.
    # charges não participa das variáveis usadas para obter clusters.
    y_treino_faixas = pd.qcut(
        y_treino, q=3, labels=["Baixo", "Médio", "Alto"]
```

```
    )

    # 3. Aplicar dois algoritmos de agrupamento com três clusters.
    kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
    labels_kmeans = kmeans.fit_predict(X_treino_preparado)
    hierarquico = AgglomerativeClustering(n_clusters=3, linkage="ward")
    labels_hierarquico = hierarquico.fit_predict(X_treino_preparado)

    # 4. Métricas externas e interna.
    ari_kmeans = adjusted_rand_score(y_treino_faixas, labels_kmeans)
    nmi_kmeans = normalized_mutual_info_score(y_treino_faixas, labels_kmeans)
    sil_kmeans = silhouette_score(X_treino_preparado, labels_kmeans)
    ari_hier = adjusted_rand_score(y_treino_faixas, labels_hierarquico)
    nmi_hier = normalized_mutual_info_score(y_treino_faixas, labels_hierarquico)
    sil_hier = silhouette_score(X_treino_preparado, labels_hierarquico)

    resultados = pd.DataFrame({
        "Métrica": ["ARI", "NMI", "Coeficiente de Silhueta"],
        "K-Means": [ari_kmeans, nmi_kmeans, sil_kmeans],
        "Agrupamento Hierárquico": [ari_hier, nmi_hier, sil_hier],
    })
    print("\nComparativo dos algoritmos:")
    print(resultados.to_string(index=False, float_format=lambda n: f"{n:.6f}"))

    # 5. Tabelas cruzadas: clusters x faixas de charges.
    tabela_kmeans = pd.crosstab(
        y_treino_faixas, labels_kmeans,
        rownames=["Faixa de charges"], colnames=["Cluster K-Means"],
    )
    tabela_hier = pd.crosstab(
        y_treino_faixas, labels_hierarquico,
        rownames=["Faixa de charges"], colnames=["Cluster Hierárquico"],
    )
    print("\nDistribuição: K-Means por faixa de custo\n", tabela_kmeans)
    print("\nDistribuição: Hierárquico por faixa de custo\n", tabela_hier)

    # 6. Salvar arquivos de resultado em uma única pasta.
    RESULTADOS.mkdir(parents=True, exist_ok=True)
    resultados.to_csv(RESULTADOS / "atividade3_metricas.csv", index=False)
    tabela_kmeans.to_csv(RESULTADOS / "atividade3_matriz_kmeans.csv")
    tabela_hier.to_csv(RESULTADOS / "atividade3_matriz_hierarquico.csv")


if __name__ == "__main__":
    main()
```