INSTITUTO FEDERAL DO RIO GRANDE DO NORTE – IFRN
Campus Currais Novos

TÉCNICAS DE ANÁLISE DE DADOS

Atividade 3 – Agrupamento (clusterização) dos dados

Professor: Marcílio Meira
Alunos: Robério Batista de Azevêdo Júnior e Daniel Goes

Conjunto de dados: Medical Cost Personal Datasets (insurance.csv)

Currais Novos – RN

1. Objetivo

Esta atividade aplica dois algoritmos de agrupamento não supervisionado, K-Means e Agrupamento Hierárquico Aglomerativo, ao conjunto de dados de custos médicos (insurance.csv). O objetivo é identificar grupos nos atributos de entrada e comparar os clusters com três faixas de custo, chamadas Baixo, Médio e Alto.

Esclarecimento: a coluna charges contém valores contínuos. As três faixas não são rótulos originalmente existentes no arquivo; foram criadas por discretização em quantis para possibilitar essa comparação.

2. Metodologia de Agrupamento

Foram utilizados os dados de treinamento preparados na Atividade 2 – Pré-processamento de Dados, com 1.069 registros e 11 atributos transformados. O código completo de carregamento, limpeza, codificação e padronização foi entregue na atividade anterior e é reutilizado por esta etapa, sem necessidade de repeti-lo neste documento.

A variável-alvo charges foi mantida fora dos atributos usados para formar os clusters. Somente seus valores no conjunto de treinamento foram convertidos em três faixas usando pd.qcut(), para avaliação posterior dos grupos.

A escolha de K = 3 permite comparar os clusters produzidos pelos dois algoritmos com as três faixas de custo criadas. Não se afirma que três seja o número ótimo de grupos.

K-Means: particionamento em três grupos com base em centróides (`n_clusters=3`, `random_state=42` e `n_init=10`).
Aglomerativo: agrupamento hierárquico em três grupos pelo método de Ward, com distância euclidiana.

3. Resultados Obtidos

Foram consideradas duas métricas externas, ARI (Adjusted Rand Index) e NMI (Normalized Mutual Information), que comparam as atribuições de clusters às faixas de custo, além da métrica interna Silhouette, que avalia a separação dos grupos.

Métrica de avaliação	K-Means	Hierárquico
ARI (Adjusted Rand Index)	0,204379	0,136107
NMI (Normalized Mutual Information)	0,213334	0,133954
Coeficiente de Silhueta	0,185624	0,129670

Valores reproduzidos do relatório original da dupla. É necessário confirmar esses resultados ao executar o código atualizado com o insurance.csv original e a Atividade 2.

4. Matrizes de Contingência (Distribuição dos Grupos)

Distribuição dos clusters K-Means por faixa de custo

Faixa de charges	Cluster 0	Cluster 1	Cluster 2
Baixo	261	17	79
Médio	11	211	134
Alto	110	135	111

Distribuição dos clusters hierárquicos por faixa de custo

Faixa de charges	Cluster 0	Cluster 1	Cluster 2
Baixo	66	60	231
Médio	200	134	22
Alto	94	114	148

Nas tabelas, os identificadores 0, 1 e 2 são rótulos arbitrários dos clusters e não correspondem automaticamente a Baixo, Médio e Alto.

5. Considerações Finais

Nos resultados apresentados pela dupla, o K-Means obteve valores superiores nas três métricas, indicando maior concordância com as faixas de custo e melhor separação interna em comparação com o método hierárquico nesta execução.

Entretanto, os valores de ARI, NMI e Silhouette são relativamente baixos. Portanto, a concordância dos clusters com as três faixas e a separação entre os grupos são limitadas. Esses números, isoladamente, não demonstram que os dados sejam não lineares nem comprovam que o tabagismo seja a causa das diferenças de custos.

6. Código-fonte utilizado

O código desta atividade está a seguir. Ele executa e reutiliza o arquivo `Atividade_2_Preprocessamento_Insurance.py`, entregue na Atividade 2, e usa `insurance.csv` na mesma pasta. Desse modo, o pré-processamento permanece documentado na entrega anterior, sem duplicação de código.

Os resultados e as matrizes de contingência são exibidos no terminal e exportados em arquivos CSV para facilitar a conferência.

```
"""IFRN - Atividade 3: agrupamento de dados.
Dupla: Robério Batista de Azevêdo Júnior e Daniel Goes.
Pré-processamento: código entregue na Atividade 2.
"""

import os
import runpy
from pathlib import Path
import pandas as pd
from sklearn.cluster import KMeans, AgglomerativeClustering
from sklearn.metrics import (
```

```
    adjusted_rand_score, normalized_mutual_info_score, silhouette_score
)

# 1. Reutilizar o código de pré-processamento da Atividade 2.
pasta = Path(__file__).resolve().parent
os.chdir(pasta)
a2 = runpy.run_path(str(pasta / "Atividade_2_Preprocessamento_Insurance.py"))
X_treino_preparado = a2["X_treino_preparado"]
y_treino = a2["y_treino"]

# charges não pode entrar nos atributos usados para descobrir grupos.
atributos = a2["variaveis_numericas"] + a2["variaveis_categoricas"]
if "charges" in atributos:
    raise ValueError("A coluna charges deve ficar fora do agrupamento.")

# 2. Criar faixas de custo por quantis apenas para comparação.
# Baixo, Médio e Alto NÃO são rótulos originais da base.
y_treino_faixas = pd.qcut(y_treino, q=3, labels=["Baixo", "Médio", "Alto"])

# 3. Aplicar K-Means e Agrupamento Hierárquico (três grupos).
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
labels_kmeans = kmeans.fit_predict(X_treino_preparado)
hierarquico = AgglomerativeClustering(n_clusters=3, linkage="ward")
labels_hierarquico = hierarquico.fit_predict(X_treino_preparado)

# 4. Avaliar correspondência com as faixas e separação dos grupos.
ari_kmeans = adjusted_rand_score(y_treino_faixas, labels_kmeans)
nmi_kmeans = normalized_mutual_info_score(y_treino_faixas, labels_kmeans)
sil_kmeans = silhouette_score(X_treino_preparado, labels_kmeans)
ari_hier = adjusted_rand_score(y_treino_faixas, labels_hierarquico)
nmi_hier = normalized_mutual_info_score(y_treino_faixas, labels_hierarquico)
sil_hier = silhouette_score(X_treino_preparado, labels_hierarquico)

resultados = pd.DataFrame({
    "Métrica": ["ARI", "NMI", "Coeficiente de Silhueta"],
    "K-Means": [ari_kmeans, nmi_kmeans, sil_kmeans],
    "Agrupamento Hierárquico": [ari_hier, nmi_hier, sil_hier],
})
print("\nComparativo dos algoritmos:")
print(resultados.to_string(index=False, float_format=lambda n: f"{n:.6f}"))

# 5. Comparar os três clusters com as três faixas criadas.
tabela_kmeans = pd.crosstab(
    y_treino_faixas, labels_kmeans,
    rownames=["Faixa de charges"], colnames=["Cluster K-Means"]
)
tabela_hier = pd.crosstab(
    y_treino_faixas, labels_hierarquico,
    rownames=["Faixa de charges"], colnames=["Cluster Hierárquico"]
)
print("\nDistribuição: K-Means por faixa de custo\n", tabela_kmeans)
print("\nDistribuição: Hierárquico por faixa de custo\n", tabela_hier)

# 6. Guardar métricas e matrizes para conferir os resultados.
resultados.to_csv("atividade3_metricas.csv", index=False)
tabela_kmeans.to_csv("atividade3_matriz_kmeans.csv")
tabela_hier.to_csv("atividade3_matriz_hierarquico.csv")
```